

LABORATORIO 8, MODELOS autorregRESIVOS

Autores: Marc Delgado, Manuel Rucker

1. Introducción y Objetivos.....	1
2. Datos y preprocesamiento.....	1
3. Cuantización y discretización de las señales.....	1
4. Modelo autorregresivo (MADE).....	2
5. Resultados de los modelos autorregresivos.....	2
a. Combinación 1 (Ventana = 8, Vocabulario = 128).....	2
b. Combinación 2 (Ventana = 12, Vocabulario = 128).....	3
c. Combinación 3 (Ventana = 12, Vocabulario = 256).....	4
d. Combinación 4 (Ventana = 8, Vocabulario = 256).....	5
e. Elección del modelo y más ejemplos.....	6
6. Respuestas a las cuestiones teóricas.....	8
7. Conclusiones.....	8

1. Introducción y Objetivos

En este trabajo se aplican modelos autorregresivos para aprender la distribución de señales de electrocardiograma (ECG) pertenecientes a la clase Normal del conjunto de datos MITBIH. Un modelo autorregresivo descompone la probabilidad conjunta de una secuencia, permitiendo predecir cada elemento condicionado a todos los anteriores; esto facilita tanto la generación de nuevas secuencias como el cálculo de su verosimilitud.

Dado que las señales de ECG son continuas y presentan una alta dimensionalidad, el primer objetivo del proyecto es su cuantización. Para ello, transformamos la señal en una secuencia discreta mediante el uso de ventanas y un modelo de mezcla de Gaussianas (GMM), construyendo así un vocabulario de símbolos que representan fragmentos característicos de la señal. El segundo objetivo consiste en entrenar un modelo MADE (Masked Autoencoder for Density Estimation) adaptado para estas secuencias discretas mediante codificación one-hot, de modo que aprenda a predecir el siguiente símbolo y modele la distribución de las señales sanas.

Finalmente, se evalúa el rendimiento del modelo mediante la generación de nuevas secuencias y el cálculo de la verosimilitud en señales reales. Un punto clave del análisis es la comparación entre la verosimilitud asignada a las señales de la clase Normal frente a la de otras clases, lo que permite determinar la capacidad del modelo para diferenciar patrones fisiológicos normales de aquellos anómalos.

2. Datos y preprocesamiento

Para el desarrollo de la práctica se ha utilizado una versión simplificada de la MITBIH Arrhythmia Database, accesible a través de la librería `apafib`. Este conjunto de datos contiene señales de ECG discretizadas inicialmente en 94 puntos y etiquetadas con distintas clases de latidos cardíacos. Dado que el modelo autorregresivo tiene como fin aprender la distribución de señales sanas, el proceso comenzó filtrando y conservando únicamente los ejemplos pertenecientes a la clase Normal.

Sobre estas señales se aplicó un preprocesamiento básico que consistió en eliminar la columna de la etiqueta de clase y añadir dos columnas adicionales con valor cero (padding), resultando en señales de longitud 96. Esta longitud específica se eligió por tener múltiples divisores (como 8 y 12), lo que facilita la posterior división en ventanas de tamaño fijo durante la fase de cuantización. Por último, los datos se convirtieron a una matriz NumPy para optimizar la velocidad de cómputo en las etapas siguientes.

3. Cuantización y discretización de las señales

Debido a que los modelos autorregresivos como MADE funcionan de manera más eficaz sobre secuencias discretas, fue necesario cuantizar los valores continuos de las señales de ECG. El procedimiento se inició dividiendo cada señal de 96 puntos en fragmentos consecutivos o ventanas de longitud fija, probando dos tamaños distintos: 8 y 12 muestras. Estas ventanas permiten capturar patrones locales de la señal para que el modelo pueda identificar la estructura del latido.

Para realizar la discretización, se entrenaron modelos de Mezcla de Gaussianas (GMM) que agrupan las ventanas según su similitud. El número de componentes del GMM determina el tamaño del vocabulario de símbolos; en este caso, se experimentó con vocabularios de 128 y 256 símbolos.

Combinando los dos tamaños de ventana con los dos tamaños de vocabulario, se obtuvieron cuatro cuantizadores diferentes. Cada GMM aprende un conjunto de centroides que actúan como "protoventanas" típicas de un ECG normal. Una vez entrenados, cada ventana de la señal original se asigna al clúster más probable, transformando la señal continua en una secuencia de números enteros que representan los identificadores de dichos clústeres.

4. Modelo autorregresivo (MADE)

Para modelar la distribución de las secuencias ya discretizadas se empleó la arquitectura MADE. Dado que el modelo original suele trabajar con datos binarios, fue necesario adaptarlo para procesar vocabularios multivaluados. Esto se logró representando cada símbolo de la secuencia mediante una codificación one-hot con un tamaño igual al vocabulario empleado (128 o 256).


La arquitectura implementada consta de una capa lineal de entrada, una capa oculta con función de activación ReLU y una capa de salida cuya dimensión corresponde al producto de la longitud de la secuencia por el tamaño del vocabulario. Posteriormente, se realiza un reordenamiento para obtener una distribución de probabilidad por token. El entrenamiento se lleva a cabo de forma autorregresiva utilizando máscaras que impiden que el modelo acceda a información futura. Como función de pérdida se utilizó la entropía cruzada categórica, la cual mide la precisión con la que el modelo predice el siguiente símbolo de la secuencia. Para monitorizar el proceso y evitar el sobreajuste, los datos se dividieron en conjuntos de entrenamiento, validación y test, utilizando el optimizador Adam.

5. Resultados de los modelos autorregresivos

En esta sección se analiza el rendimiento del modelo MADE bajo las diferentes configuraciones de discretización, evaluando la calidad de la reconstrucción, la generación de señales sintéticas y la verosimilitud (Log-Likelihood) tanto en señales normales como en clases anómalas. Estas son las configuraciones que mejores resultados nos dieron, y por motivos de simplicidad, no mostraremos los resultados de otras combinaciones cuyos resultados fueron mucho más negativos.


a. Combinación 1 (Ventana = 8, Vocabulario = 128)

Aunque esta es la configuración de menor complejidad, la reconstrucción y generación no producen señales suavizadas, sino que ya manifiestan la tendencia a exagerar la amplitud de los picos R. Al utilizar ventanas cortas, el modelo logra mantener una buena coherencia temporal (el ritmo es estable), pero las transiciones entre tokens generan una morfología visualmente más agresiva que la de un ECG real. En términos cuantitativos, el modelo aprende una distribución robusta, obteniendo una verosimilitud media en test de -1.8956 y manteniendo una excelente capacidad de discriminación frente a anomalías (-9.4628).




b. Combinación 2 (Ventana = 12, Vocabulario = 128)

Al aumentar el tamaño de ventana, la morfología generada mantiene la característica de picos pronunciados observada anteriormente. Sin embargo, esta configuración destaca por ser la más exitosa estadísticamente, alcanzando la mejor verosimilitud en el conjunto de test (-0.8696). Esto indica que el modelo predice las secuencias de tokens con gran confianza. No obstante, esta alta confianza y flexibilidad parecen jugar en contra de la detección de anomalías: la verosimilitud para las clases patológicas subió a -5.3800, reduciendo significativamente el margen de separación respecto a la configuración de ventana 8.




c. Combinación 3 (Ventana = 12, Vocabulario = 256)

En esta configuración, al duplicar el vocabulario manteniendo la ventana grande, el fenómeno de exageración de picos se intensifica y se mezcla con inestabilidad. La señal reconstruida y generada presenta segmentos irregulares y transiciones abruptas, producto de un sobreajuste a centroides muy específicos y ruidosos. Visualmente, los latidos generados tienen amplitudes desproporcionadas. Este ruido estructural penaliza el rendimiento estadístico: la verosimilitud en test cae a -1.9471, empeorando respecto a la Combinación 2. No obstante, esta rigidez y complejidad ayudan a la detección de anomalías, bajando la verosimilitud de otras clases a -8.3818 y recuperando capacidad discriminativa a costa de la calidad visual de la generación.




d. Combinación 4 (Ventana = 8, Vocabulario = 256)

Finalmente, se evaluó la configuración con ventanas de 8 muestras y un vocabulario de 256 símbolos. Aquí también se observa la tendencia general de las configuraciones complejas: la señal generada presenta picos notablemente más agudos y exagerados que la señal real, aunque mantiene una coherencia temporal superior a la Combinación 3 gracias al uso de ventanas más cortas. A pesar de esta distorsión en la amplitud (que aleja la señal sintética de la suavidad biológica real), el modelo logra un consenso sólido entre modelado y discriminación. Cuantitativamente, obtuvo una verosimilitud en test de -1.9481, muy similar a las otras configuraciones estables, y una verosimilitud para clases anómalas de -8.4541. Esto confirma que, aun con la tendencia a exagerar morfologías, el modelo discrimina con gran eficacia los latidos patológicos de los normales.



e. Elección del modelo y más ejemplos

Considerando la aplicación final de diagnóstico médico, la configuración de Ventana=8 y Vocabulario=256 se establece como la mejor opción porque ofrece el compromiso más robusto entre calidad estructural y utilidad clínica. Si bien la configuración de ventana 12 obtuvo una métrica de ajuste teórica superior, su excesiva flexibilidad provocó que tolerara patrones anómalos, fallando en la tarea crítica de detección. Por el contrario, la combinación seleccionada (8, 256) no solo preserva mejor la coherencia temporal del latido gracias a la ventana corta y captura detalles finos mediante el vocabulario amplio, sino que fundamentalmente maximiza la capacidad discriminativa, manteniendo el mayor margen de separación entre señales sanas y patológicas, lo cual es el criterio prioritario para un sistema de detección de anomalías eficaz. A continuación, veremos algunos ejemplos más de datos generados por este modelo.



6. Respuestas a las cuestiones teóricas

Incomparabilidad de la función de pérdida: Los valores de la función de pérdida (Negative Log-Likelihood) no son comparables entre los diferentes experimentos porque al cambiar el tamaño de la ventana, cambia la longitud de la secuencia (T) que el modelo debe predecir. Una secuencia más corta (ventana 12) acumula menos términos de error que una larga (ventana 8), alterando la escala de la pérdida total. Además, al cambiar el tamaño del vocabulario, cambia la entropía base del problema de clasificación.

Modificación del modelo (Embeddings): Para que el modelo MADE trabaje eficientemente con el vocabulario directo (índices enteros) en lugar de one-hot, se debe añadir una capa de Embedding al inicio de la red. Esto proyecta los índices discretos a un espacio vectorial denso y continuo. La función de pérdida para el entrenamiento seguiría siendo la Entropía Cruzada (Cross-Entropy), ya que la naturaleza del problema (predecir la probabilidad de la siguiente clase) se mantiene igual.

7. Conclusiones

El desarrollo de esta práctica ha permitido validar la eficacia de los modelos autorregresivos (MADE) para el modelado de señales fisiológicas, revelando hallazgos importantes sobre el proceso de discretización:

Sesgo de agudización en la cuantización: Contrario a la intuición inicial de que una menor resolución suavizaría la señal, se concluye que la discretización mediante GMM tiende sistemáticamente a exagerar la amplitud de los picos en la reconstrucción. Este artefacto visual está presente en todas las configuraciones y sugiere que los centroides del GMM capturan con mucha fuerza las variaciones rápidas de la señal.

Compromiso entre confianza y discriminación: La configuración que obtuvo la mejor métrica de ajuste (Ventana=12, Vocabulario=128) fue, paradójicamente, la menos eficaz para la detección de anomalías. Esto demuestra que un modelo que asigna probabilidades muy altas a sus predicciones (sobreajuste a la estructura de tokens) puede volverse demasiado "permisivo", perdiendo sensibilidad para distinguir patrones patológicos.

Ventajas de ventanas pequeñas: Las configuraciones con ventanas de 8 muestras demostraron ser más robustas para la tarea de detección de anomalías y generaron señales visualmente más estables. La combinación Ventana=8 / Vocabulario=256 se identifica como la más equilibrada, ofreciendo buena calidad generativa y una excelente separación entre clases normales y enfermas.