

PRÀCTICA 2-APRNS

Mètodes Actor-Critic Off-Policy: DDPG i TD3

Marc Delgado Gallardo
Mattias Fuguet Yandell

Índex

1. Introducció i objectius	3
2. Descripció del problema i de l'entorn LunarLander continu	3
3. Implementació del DDPG	4
3.1. Replay Buffer	4
3.2. Política determinista i soroll d'exploració OU	5
3.3. Càlcul del Critic Loss (MSBE)	5
3.4. Càlcul de l'Actor Loss (maximització de Q)	5
3.5. Algorisme complet i cicle d'entrenament	5
4. Implementació del TD3	6
4.1. Twin Critics i minimització de Q	6
4.2. Soroll de suavitzat de la política objectiu (Target Policy Smoothing)	6
4.3. Actualitzacions retardades de l'Actor i les xarxes Target	7
4.4. Algoritme complet	7
5. Experiments i resultats	7
5.1. Configuració d'entrenament	7
5.2. Evolució de la recompensa del DDPG	8
5.3. Evolució de la recompensa del TD3	11
6. Anàlisis dels resultats obtinguts	14
7. Conclusions	14
8. Referències	15

1. Introducció i objectius

En aquest laboratori estudiem mètodes *off-policy* d'Actor-Critic orientats al control d'entorns amb accions contínues. L'objectiu és implementar i analitzar dues de les metodologies més influents en aquest àmbit: DDPG (Deep Deterministic Policy Gradient) i la seva extensió TD3 (Twin Delayed Deep Deterministic Policy Gradient). Ambdues combinen un *critic* que aprèn la funció de valor d'acció $Q(s,a)$ amb un *actor* que aprèn una política determinista capaç de generar accions contínues en entorns complexos, no lineals i amb transicions altament sensibles al control.

Per validar i comparar les implementacions, entrenem els agents en la versió contínua del LunarLander-v3, un entorn en què un mòdul lunar ha d'aterrar de manera precisa utilitzant un conjunt d'accions reals. Aquest escenari és especialment adequat perquè exigeix estabilitat, control fi i capacitat per generalitzar en dinàmiques amb fortes dependències temporals.

Els objectius del treball són diversos. En primer lloc, implementar un agent DDPG complet, incloent un Replay Buffer per gestionar experiències passades, xarxes *Actor* i *Critic* amb inicialització especialitzada i normalització segons les directrius del paper original, una política determinista combinada amb soroll d'exploració d'Ornstein-Uhlenbeck i un mecanisme d'actualització suau de les xarxes *target* que garanteix estabilitat durant l'entrenament.

En segon lloc, implementem les millores proposades pel mètode TD3, que introdueix diverses modificacions per reduir la sobreestimació del Critic i millorar la robustesa del procés d'aprenentatge: l'ús de dos Critics independents, l'addició de soroll gaussià truncat en la política objectiu i un entrenament retardat de l'Actor que evita actualitzacions inestables.

Finalment, es realitza una comparació entre ambdós algorismes per avaluar la seva velocitat d'aprenentatge, l'estabilitat, la qualitat final de la política i la sensibilitat als hiperparàmetres recomanats als articles originals. Tot plegat permet obtenir una visió clara de les fortaleces i limitacions de cadascun dels mètodes en un entorn de control continu exigent.

2. Descripció del problema i de l'entorn LunarLander continu

L'entorn LunarLander-v3 en versió contínua simula l'aterratge d'un mòdul lunar utilitzant motors continus. L'objectiu de l'agent és portar la nau fins a una plataforma central, mantenint una trajectòria estable i minimitzant tant la velocitat com la inclinació en el moment del contacte. Aquest entorn representa un repte típic de control òptim amb dinàmiques no lineals i un espai d'accions real-valuat, fet que el converteix en un escenari adequat per algoritmes com DDPG i TD3.

L'espai d'estats està format per vuit variables contínues que descriuen completament la configuració del sistema: posició horitzontal i vertical, velocitats en ambdós eixos, angle i velocitat angular, així

com dues variables binàries que indiquen si cadascuna de les potes ha pres contacte amb el sòl. Aquest conjunt d'informació proporciona totes les dades necessàries perquè l'agent pugui predir les conseqüències de les seves accions i aprendre un control efectiu de l'aterratge.

L'espai d'accions és continu i de dues dimensions. El primer component controla la intensitat del motor principal, que genera empenta vertical, i el segon actua sobre els motors laterals, responsables de l'estabilització i del control de l'angle. Ambdós valors són reals dins de l'interval $[-1, 1]$, la qual cosa obliga l'agent a seleccionar accions precises i fines, i fa inviable l'ús d'algoritmes basats en accions discretes com DQN o DDQN.

La funció de recompensa penalitza moviments bruscos, velocitats elevades i desviacions de la zona d'aterratge, mentre que atorga increments positius quan el mòdul redueix la velocitat, manté una inclinació adequada o estableix un contacte segur amb el terra. L'episodi finalitza quan l'aterratge és satisfactori, quan la nau s'estavella o quan s'assoleix el límit de temps. Tot plegat crea un entorn on la política ha d'equilibrar estabilitat, consum de combustible i precisió del moviment, aspectes característics dels problemes reals de control continu.

3. Implementació del DDPG

En aquest laboratori hem implementat l'algorisme Deep Deterministic Policy Gradient (DDPG), seguint l'arquitectura i les recomanacions del paper original "*Continuous Control with Deep Reinforcement Learning*" de Lillicrap et al. (2016).

El conjunt d'hiperparàmetres emprats en aquesta implementació segueix estrictament els valors proposats pels autors del paper, incloent els learning rates, la tècnica d'exploració Ornstein–Uhlenbeck noise, l'ús d'optimitzadors Adam i el soft update de xarxes target amb un valor de $\tau = 0.001$, tots ells fonamentals per assolir estabilitat en problemes de control continu.

A continuació es descriu de manera detallada cada component de la nostra implementació.

3.1. Replay Buffer

DDPG és un algorisme off-policy, i per tant necessita un Replay Buffer per trencar la correlació temporal entre transicions consecutives. Tal com recomana el paper, utilitzem un buffer de gran capacitat que emmagatzema tuple.

Aquest mecanisme permet mostrar a l'agent experiències passades barrejades aleatòriament, fet que redueix la variància del gradient i millora l'estabilitat de l'entrenament. La implementació utilitzada és exactament la mateixa que en el laboratori de DQN de sessions anteriors, ja que el mecanisme de mostra aleatòria i reemplaçament circular és idèntic en tots dos casos. L'única diferència és que aquí les accions poden ser vectors continus, però el buffer és general i admet qualsevol tipus de dades.

Aquest component segueix de manera literal l'estructura proposada a Lillicrap et al. (2016), on el replay buffer és considerat un element essencial per aconseguir aprenentatge estable en entorns continus.

3.2. Política determinista i soroll d'exploració OU

La política de DDPG és determinista. A diferència d'algoritmes estocàstics com PPO o REINFORCE, aquí la política sempre retorna l'acció "òptima" segons l'actor. Per aquest motiu, el paper proposa afegir un procés estocàstic extern durant l'entrenament per garantir exploració:

El soroll d'Ornstein–Uhlenbeck (OU) és especialment adequat per accions físiques perquè genera soroll temporalment correlacionat, imitant la inèrcia de sistemes mecànics. En el nostre cas utilitzem els paràmetres recomanats:

- $\theta = 0.15$,
- $\mu = 0$,
- $\sigma = 0.2$

tal com s'especifica explícitament a la taula d'hiperparàmetres del paper. Aquest soroll es clipeja a l'interval $[-1,1][[-1, 1][[-1,1]$ per garantir accions vàlides dins de l'espai continu del LunarLander.

3.3. Càlcul del Critic Loss (MSBE)

El Critic aprèn a aproximar la funció Q seguint l'equació de Bellman. Igual que al paper, utilitzem la Mean Squared Bellman Error (MSBE), on el *target* es calcula amb les xarxes *target*.

Aquesta formulació és exactament la descrita a l'article, i garanteix que els *targets* evolucionen lentament gràcies a la presència de xarxes *target* actualitzades amb *soft updates*. L'ús d'Adam amb *learning rate* 10 a la menys 3 i *weight decay* està també alineat amb les especificacions originals.

3.4. Càlcul de l'Actor Loss (maximització de Q)

L'Actor es defineix com una xarxa neuronal que maximitza el valor que el Critic assigna a les seves accions.

Tal com indica Lillicrap., és suficient amb prendre el gradient respecte als paràmetres de la política, ja que el Critic proporciona una estimació diferenciable del valor futur de cada acció. Utilitzem un *learning rate* de 10 a la menys 4, tal com proposa el paper, per mantenir estable l'aprenentatge de la política.

3.5. Algorisme complet i cicle d'entrenament

El cicle d'entrenament segueix de manera fidel l'algorisme oficial del paper:

1. Rebre estat inicial del medi.
2. Seleccionar acció determinista i afegir soroll OU.
3. Aplicar acció i guardar la transició al Replay Buffer.
4. Mostrar un batch de transicions aleatòries.
5. Actualitzar el Critic mitjançant MSBE.
6. Actualitzar l'Actor maximitzant Q.
7. Actualitzar xarxes *target* amb *soft update*', utilitzant $\tau = 0.001$, tal com recomana el paper.
8. Repetir fins a final d'episodi.

Aquest procés combina els avantatges de la política determinista amb l'estabilitat dels *soft updates*, fet que permet entrenar agents en entorns continus.

4. Implementació del TD3

L'algoritme Twin Delayed Deep Deterministic Policy Gradient (TD3) es va proposar com una millora directa del DDPG per abordar problemes específics com la sobreestimació dels valors Q i l'alta sensibilitat als hiperparàmetres. Hem implementat TD3 sobre la base del DDPG, introduint tres canvis estructurals proposats per Fujimoto et al. (2018):

4.1. Twin Critics i minimització de Q

Un problema del DDPG és que el critic tendeix a sobreestimar els valors Q, que es propaga a través de l'equació de Bellman. TD3 arregna això utilitzant dos critics independents amb inicialitzacions aleatòries diferents. Durant el càlcul del *target*, s'utilitza el mínim dels dos valors predits per les xarxes target. Aquesta estratègia, coneguda com *Clipped Double Q-Learning*, afavoreix una estimació més conservadora i redueix el biaix de sobreestimació.

4.2. Soroll de suavitzat de la política objectiu (Target Policy Smoothing)

Per evitar que el critic faci overfitting, en el TD3 introduïm soroll a l'acció utilitzada per calcular el target. Aquest soroll és gaussià i es trunca per mantenir-lo dins d'un rang raonable. Això actua com una forma de regularització, forçant al critic a aprendre valors similars per a accions similars, que suavitza la superfície de valor. En la nostra implementació hem utilitzat $\sigma=0.2$ i $c=0.5$, que hem trobat que eren els valors òptims després de fer unes quantes execucions de prova.

4.3. Actualitzacions retardades de l'Actor i les xarxes Target

En DDPG, l'actor i el critic s'actualitzen a cada pas. Això pot ser problemàtic perquè l'actor intenta maximitzar un critic que encara està canviant i pot ser inexacte. TD3 proposa actualitzar l'actor (i les xarxes target) amb menys freqüència que el critic. En la nostra implementació, mantenim un retard $d=2$, és a dir, actualitzem els pesos de l'actor i realitzem els soft updates només una vegada per cada dues actualitzacions del critic. Això permet que el critic tingui temps de reduir l'error TD abans que la política canviï, millorant l'estabilitat.

4.4. Algoritme complet

El codi final integra aquestes tres millores en l'estructura del DDPG. Es manté l'ús del Replay Buffer i l'exploració inicial. Els hiperparàmetres utilitzats són els recomanats al paper de TD3, amb una taxa d'aprenentatge de 10^{-3} per a tots dos components i $\tau=0.005$ per als soft updates, lleugerament superior al de DDPG degut a la menor freqüència d'actualització.

5. Experiments i resultats

5.1. Configuració d'entrenament

Per entrenar tant l'agent DDPG com el TD3 hem utilitzat l'entorn LunarLander-v3 (continuous) del paquet Gymnasium. En ambdós casos, el nombre màxim de passos per entrenament s'ha fixat a 500.000 timesteps, seguint les directrius del laboratori. Tot i això, en totes les execucions l'entrenament s'ha aturat abans d'arribar a aquest límit, ja que la implementació inclou una condició de parada addicional: quan la mitjana de les últimes cinc avaluacions supera els 220 punts, el procés d'entrenament es considera satisfactori i es finalitza automàticament.

Pel que fa als hiperparàmetres, s'han respectat les especificacions dels treballs originals per a cada algorisme. Per al DDPG, s'han utilitzat els valors proposats per Lillicrap et al. (2016), fent ús del soroll d'Ornstein-Uhlenbeck per a l'exploració. Per al TD3, s'han adoptat els paràmetres de Fujimoto et al. (2018), substituint el soroll OU per soroll gaussià simple, tal com recomana l'article per millorar la simplicitat i robustesa.

Cada execució és independent i no s'ha fixat cap llavor aleatòria, de manera que l'estat inicial de les xarxes, del buffer de reproducció i del procés de soroll pot variar significativament entre entrenaments. Aquest fet és especialment important per comparar l'estabilitat, donada l'alta variància del DDPG comparat amb les millores d'estabilitat introduïdes pel TD3.

5.2. Evolució de la recompensa del DDPG

Per analitzar el comportament del DDPG, s'han realitzat tres execucions completes, obtenint els gràfics d'evolució de recompensa que es mostren a continuació.

Primera execució (fins aproximadament 200.000 passos)

La primera corba mostra un comportament típic del DDPG: una fase inicial molt inestable amb recompenses fortament negatives degut a l'exploració i a l'efecte del soroll OU. A partir dels 150–200 episodis, la tendència comença a ser positiva. Entre els episodis 200 i 400, la política mostra millores constants i alguns episodis amb recompenses superiors a 200, evidenciant que l'agent és capaç d'aterrar correctament en diverses ocasions.

La variància, però, continua sent elevada, i encara s'observen caigudes brusques en determinats episodis, cosa completament coherent amb el comportament descrit a la literatura per aquest algorisme.





Figura: Evolució del reward en la primera execució

Segona execució (fins aproximadament 300.000 passos)

En aquest segon entrenament, l'evolució general també mostra una millora progressiva, però amb un perfil diferent. Aquesta execució ha començat amb una exploració encara més agressiva, reflectida en episodis inicials amb recompenses molt negatives. Tot i això, a partir dels episodis 150–200, torna a emergir una tendència ascendent.


En comparació amb la primera execució, la segona presenta una variabilitat més accentuada i una estabilització més lenta. A partir dels episodis 400–500, la corba indica episodis bons i dolents alternats, però amb una mitjana que globalment millora. Igual que en el primer cas, l'entrenament ha finalitzat abans d'arribar als 500.000 timesteps perquè la condició de parada alternativa s'ha satisfet (mitjana recent superior als 220 punts en algun moment).



Tercera execució (fins aproximadament 175.000 passos)

La tercera execució ha sigut sens dubte la millor de les tres, presenta una evolució similar però encara més compacta: l'agent aconsegueix estabilitzar-se molt abans. Tot i començar amb recompenses negatives, l'ascens és més ràpid i sostingut, i al voltant dels episodis 350–450 ja s'observen episodis repetits amb recompenses superiors als 200–250 punts.

Malgrat la presència de certa variabilitat, aquesta execució és la que mostra una estabilització més clara i una tendència ascendent més neta, suggerint que amb una llavor aleatòria favorable el DDPG pot convergir més ràpid cap a polítiques d'aterratge eficients.



Comparació entre execucions

Tot i que el patró general és similar—millora progressiva, alta variabilitat, estabilització parcial—les tres execucions difereixen en el ritme i la forma d'aquesta evolució. Aquesta diferència és perfectament normal en DDPG. L'algorisme presenta una sensibilitat elevada a:

- la inicialització de les xarxes,
- l'ordre en què arriben les experiències al Replay Buffer,
- el soroll d'Ornstein–Uhlenbeck,
- i la naturalesa *off-policy* de l'actualització.

Això genera entrenaments amb formes molt diferents, tot i utilitzar exactament els mateixos hiperparàmetres.

Aquestes observacions són coherents amb el que s'espera del DDPG i justifiquen per què molts treballs posteriors, com TD3, introdueixen millores per reduir la sobreestimació, la inestabilitat i la sensibilitat a la inicialització.

5.3. Evolució de la recompensa del TD3

De manera anàloga a l'anàlisi del DDPG, hem fet tres execucions completes de l'algoritme TD3 per avaluar-ne el rendiment i la consistència. Els gràfics següents mostren l'evolució de la recompensa acumulada per episodi.

Primera execució (fins aproximadament 50.000 passos)

Aquesta execució mostra el millor comportament possible de l'algorisme. L'agent TD3 aconsegueix aprendre la tasca eficientment, assolint la condició de parada en poc més de 130 episodis. La corba d'aprenentatge presenta una tendència ascendent pràcticament constant des de l'inici, superant ràpidament la fase de recompenses negatives. A diferència del DDPG, no s'observen grans oscil·lacions ni caigudes catastròfiques un cop la política comença a millorar. La variància (zona ombrejada) es manté controlada, indicant que les actualitzacions dels crítics són estables i guien l'actor de manera fiable cap a l'objectiu.





Figura: Evolució del reward en la primera execució


Segona execució (fins aproximadament 220.000 passos)

La segona execució presenta un patró diferent, amb un llarg període d'estancament al voltant de recompensa 0. Entre els episodis 50 i 280, l'agent sembla haver après una política subòptima però segura (hem pogut comprovar que es manté a l'aire sense estavellar-se, generant el vídeo dels episodis intermedis), evitant les penalitzacions greus però sense aconseguir l'aterratge perfecte. No obstant, és destacable la robustesa de l'algoritme: en lloc d'empitjorar la política i per tant la recompensa, el TD3 manté el rendiment estable fins que, al voltant de l'episodi 290, descobreix la política òptima i la recompensa es dispara fins a superar els 240.



Tercera execució (fins aproximadament 260.000 passos)

La tercera execució és molt semblant a la segona. S'observa una fase inicial molt breu de recompenses negatives seguida d'una llarga fase d'estabilitat al voltant de 0. Finalment, cap a l'episodi 320, l'agent aconsegueix trencar aquest òptim local i aprèn ràpidament a aterrar al centre de la plataforma. Aquesta execució reforça la idea que el TD3 prioritza la seguretat i l'estabilitat: evita les actualitzacions errònies i arriscades que portarien a polítiques molt dolents, encara que això signifiqui a vegades trigar més temps a trobar la política òptima.



6. Anàlisi dels resultats obtinguts

L'anàlisi dels resultats mostra clarament que el TD3 resol eficaçment les inestabilitats del DDPG. Gràcies a la introducció dels Twin Critics i la minimització del valor Q, el TD3 elimina la sobreestimació que causava el mal rendiment observat en el DDPG, oferint una convergència molt més estable i monòtona. A més, el TD3 demostra una gran robustesa davant les condicions inicials, eliminant la dependència de la sort en la inicialització dels pesos que afecta el DDPG i fent innecessari repetir entrenaments per trobar una bona llavor. Finalment, la tècnica de Target Policy Smoothing permet al TD3 generar superfícies de valor més suaus, la qual cosa es tradueix en un control del mòdul lunar menys brusc i més precís que el DDPG.

7. Conclusions

En aquest laboratori hem abordat el repte del control continu mitjançant la implementació i comparació de dos algoritmes clau en l'aprenentatge per reforç: DDPG i TD3. Aquesta pràctica ens ha permès comprovar experimentalment les limitacions del DDPG, un algoritme eficient però molt

inestable i amb una forta dependència dels hiperparàmetres i de la inicialització aleatòria. Tot i demostrar capacitat per resoldre l'entorn, hem observat que la seva tendència a la sobreestimació dels valors Q sovint genera polítiques subòptimes o en molt mal rendiment.

Per contra, amb la implementació del TD3 hem validat l'eficàcia de les tres millores introduïdes en el paper: l'ús de Twin Critics, el suavitzat de la política objectiu (Target Policy Smoothing) i les actualitzacions retardades. Els resultats experimentals que hem obtingut mostren de manera consistent que aquests mecanismes aconseguixen en general arreglar el biaix de sobreestimació i reduir la variància, resultant en corbes d'aprenentatge més suaus i robustes.

En conclusió, aquesta pràctica ens demostra que, tot i que el DDPG estableix les bases de l'Actor-Critic off-policy per a espais continus, el TD3 representa una evolució necessària per a la seva aplicabilitat real. La capacitat del TD3 per aprendre de manera fiable sense requerir un ajust tan precís el converteix en l'opció superior per a tasques de control complexes, oferint un equilibri òptim entre eficiència i estabilitat en l'execució.

8. Referències

- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra, "Continuous control with deep reinforcement learning," in *Icml 2016*, 2016, pp. 1–14. [Online]. Disponible: <http://arxiv.org/abs/1509.02971>
- S. Fujimoto, H. van Hoof, and D. Meger, "Addressing Function Approximation Error in Actor-Critic Methods," in *35th International Conference on Machine Learning*, feb 2018. [Online]. Disponible: <http://arxiv.org/abs/1802.0947>