

APRNS - P4

MODELS DE FLUX

Marc Delgado i Gerard Garcia
Barcelona, 22/12/2025

ÍNDIX

1. Introducció	3
1.Introducció 2	3
2. Dataset utilitzat	4
2.1. Preprocessament	5
2.2. Divisió Train / Validació	5
2.Dataset utilitzat 2	5
2.1. Preprocessament i Augment de Dades	6
2.2. Partició de les Dades	6
3. Model Glow	6
3.1. Arquitectura utilitzada	6
3.2. Entrenament del Glow	7
3.3. Resultats del Glow	7
4. Generació de dades sintètiques	8
4.1. Mostreig amb Temperatura Reduïda	9
4.2. Estratègia de Generació Robusta (Filtratge de NaNs)	9
4.3. Observació sobre el Condicionament de Classes	9
5. Classificador ResNet18	10
5.1. Arquitectura (Adaptació a Baixa Resolució)	10
5.2. Escenaris d'entrenament	10
5.2.1 Baseline (Només dades reals)	10
5.2.2 TSTR: Train on Synthetic, Test on Real (Només dades sintètiques)	11
5.2.3 Data Augmentation (Dades Mixtes)	11
6. Resultats experimentals	11
6.1. Model entrenat amb dades reals	11
6.2. Model entrenat amb dades sintètiques	11
6.3. Model entrenat amb dades mixtes	11
7. Anàlisi del latent space (opcional si fas Celda F)	11
8. Conclusions	11

1.Introducció

Aquest informe documenta l'estudi i implementació de models de Normalizing Flows, centrant-se en la seva capacitat per modelar distribucions de probabilitat complexes mitjançant transformacions bijectives. A diferència d'altres famílies generatives com les GANs o els VAEs, els fluxos normalitzadors ofereixen l'avantatge teòric del càlcul exacte del Log-Likelihood i una representació latent directament invertible.

Per a aquest propòsit, s'ha utilitzat l'arquitectura Glow (Kingma & Dhariwal, 2018), entrenada sobre el dataset Smiling or Not per a la generació condicional de cares a resolució 32x32.

Més enllà de l'anàlisi qualitativa i de reconstrucció, l'estudi avalua la utilitat pràctica de les mostres generades mitjançant una validació creuada amb un classificador discriminatiu. S'ha implementat una ResNet-18 modificada (sense pooling inicial agressiu) per dur a terme tres experiments de classificació:

1. Baseline: Entrenament exclusivament amb dades reals.
2. TSTR (Train on Synthetic, Test on Real): Avaluació de la qualitat estructural i semàntica de les dades generades. Entrenem el model amb les dades que hem generat sintèticament amb Glow, però ho avaluem amb les dades reals.
3. Data Augmentation: Avaluació de la capacitat del model generatiu per actuar com a regularitzador en un entorn mixt.

Els resultats obtinguts permeten discutir les fortaleeses del Glow en la compressió d'informació (reconstrucció) en contrast amb les seves limitacions en el condicionament semàntic de classes en resolucions baixes.

2. Dataset utilitzat

Per als experiments d'aquest laboratori s'ha utilitzat el dataset Smiling or Not, proporcionat mitjançant la llibreria apafib. El conjunt consta de 1.203 imatges de cares humanes a color (RGB) amb una resolució de 32x32 píxels.

Cada mostra està associada a una etiqueta binària que descriu l'expressió facial:

- 0: La persona no somriu.
- 1: La persona somriu.

Reptes del Dataset: Malgrat la seva simplicitat aparent, aquest conjunt de dades presenta dificultats significatives per a l'entrenament de models generatius profunds:

1. Escassetat de dades: 1.203 mostres és un volum insuficient per garantir la generalització sense tècniques de regularització.
2. Baixa resolució: Amb 32×32 píxels, els trets facials (ulls, boca) ocupen molt pocs píxels, dificultant la captura de detalls fins.

2.1. Preprocessament i Augment de Dades

Per adaptar les dades als requisits matemàtics dels models, s'han aplicat les següents transformacions:

- Conversió Tensorial: Transformació a format (N, C, H, W) compatible amb PyTorch.
- Dequantization (Per a Glow): Com que els Normalizing Flows modelen densitats contínues, les dades discretes (0-255) poden provocar inestabilitat numèrica (densitats infinites). S'ha aplicat dequantization afegint soroll uniforme $u \in [0,1)$ als píxels normalitzats.
- Normalització (Per a ResNet): Per al classificador, s'han normalitzat les imatges al rang $[-1,1]$ per accelerar la convergència de l'optimitzador.
- Data Augmentation: Per mitigar l'escassetat de dades, durant l'entrenament s'han aplicat transformacions aleatòries (com RandomHorizontalFlip) per augmentar la variabilitat efectiva del dataset.

2.2. Partició de les Dades

Seguint una estratègia estratificada per mantenir la proporció de classes, el dataset s'ha dividit en:

- Entrenament (80%): 962 imatges.
- Validació (20%): 241 imatges.

A causa de la mida reduïda del dataset, no s'ha reservat un conjunt de Test separat; el conjunt de validació actua com a referència final per a l'avaluació de la pèrdua (Loss) i la precisió (Accuracy) en tots els experiments.

3. Model Glow

Per abordar el problema de modelatge generatiu, s'ha implementat una variant de l'arquitectura Glow. Aquesta arquitectura permet l'aprenentatge d'una distribució de probabilitat complexa $P_X(x)$ transformant-la en una distribució latent simple $P_Z(z)$ (típicament una gaussiana $N(0,I)$) mitjançant una seqüència de transformacions bijectives i derivables.

3.1. Arquitectura utilitzada

L'arquitectura implementada s'ha dissenyat específicament per a imatges de resolució 32×32 . El model segueix una estructura multi-escala per processar la informació a diferents nivells d'abstracció i reduir el cost computacional.

Els components clau de l'arquitectura són:

1. Operació Squeeze: Redueix la resolució espacial ($H \times W$) a la meitat i multiplica per 4 el nombre de canals (C), permetent que el model processi patrons globals a mesura que augmenta la profunditat.
2. Pas de Flux (Flow Step): El bloc constructiu bàsic, repetit K vegades per cada escala, que consta de tres sub-capes:
 - ActNorm: Normalització d'activacions per canal (similar a Batch Norm però depenent de les dades) per estabilitzar l'entrenament.
 - Convolució 1×1 Invertible: Una generalització apresada de la permutació de canals, que permet barrejar la informació entre ells de manera reversible.
 - Capa d'Acoblament Afí (Affine Coupling Layer): La part més potent del model. Divideix els canals en dues parts; una part es manté igual i l'altra es transforma mitjançant una funció afí (escala i translació) calculada per una xarxa neuronal (una ResNet petita) a partir de la primera part. Això garanteix que la transformació sigui fàcilment invertible i que el determinant del Jacobipà sigui trivial de calcular.

La configuració final escollida després de la cerca d'hiperparàmetres (Grid Search) consta de 3 escales i 8 blocs de flux per escala, amb una amplada de canal oculta de 64 a les xarxes d'acoblament.

3.2. Entrenament del Glow

L'objectiu de l'entrenament ha estat maximitzar el logaritme de la versemblança (Log-Likelihood, LL) de les dades reals.

Per garantir l'estabilitat i la convergència, s'han aplicat les següents estratègies tècniques:

- Dequantization: Com que els Normalizing Flows estan definits per a variables contínues, les dades d'imatge discretes (valors 0–255) poden provocar col·lapse del LL (valors infinits). S'ha aplicat dequantization variacional afegint soroll uniforme $u \in [0,1]$ a les dades d'entrada.
- Estratègia "Long Run": A diferència dels entrenaments estàndard, s'ha optat per un entrenament estès (>200 èpoques) utilitzant un optimitzador Adam amb un Scheduler dinàmic (ReduceLROnPlateau). Això ha permès refinar els pesos fins a un Learning Rate de l'ordre de 10^{-5} , capturant detalls d'alta freqüència.
- Data Augmentation: Per evitar el sobreajustament donat el petit tamany del dataset, s'han aplicat transformacions aleatòries (rotacions lleugeres i volteig horitzontal) durant l'entrenament.


3.3. Resultats del Glow

L'entrenament ha finalitzat amb un èxit notable en termes probabilístics, assolint un Log-Likelihood de validació superior a 10.000 nats. Aquest valor indica que el model ha aconseguit mapar gairebé la totalitat de la densitat de probabilitat de les cares al centre de la distribució latent.

Per validar la qualitat de l'aprenentatge, s'ha realitzat una anàlisi de reconstrucció en 4 nivells (Veure Figura 3.1):

1. Identitat Visual: La reconstrucció $x \rightarrow z \rightarrow x^{\wedge}$ és visualment indistingible de l'original.
2. Anàlisi de Residus ($x200$): En visualitzar la diferència absoluta $|x - x^{\wedge}|$ amplificada per un factor de 200, no s'observa soroll aleatori, sinó estructures coherents (siluetes). Això demostra

que no és una còpia trivial en memòria, sinó que existeix un processament matemàtic real, i que l'error residual és atribuïble únicament a la precisió de punt flotant (float32).



Pel que fa a la generació (sampling), s'ha utilitzat una temperatura reduïda de $T=0.7$ per filtrar mostres de baixa probabilitat, obtenint rostros amb coherència global, tot i que presenten certs artefactes de textura d'alta freqüència inherents als models basats en MLE.

4. Generació de dades sintètiques

Un cop validada la capacitat del model Glow per reconstruir imatges, el següent pas ha estat utilitzar-lo com a generador estocàstic per crear un nou conjunt de dades sintètic (Synthetic Dataset).

El procés de generació es basa en la invertibilitat del flux: es mostregen vectors latents z d'una distribució gaussiana i es projecten a l'espai de píxeles mitjançant la transformació inversa $x=f^{-1}(z)$.

4.1. Mostreig amb Temperatura Reduïda

Durant les proves preliminars, es va observar que mostrejar directament de la distribució prior $N(0,I)$ (Temperatura $T=1.0$) produïa ocasionalment imatges amb artefactes severos o colors saturats, corresponents a regions de baixa probabilitat de la distribució apresada.

Per millorar la qualitat perceptual i l'estabilitat estructural de les cares, s'ha aplicat la tècnica de Mostreig amb Temperatura Reduïda (Reduced Temperature Sampling):

$$z \sim N(0, T^2 \cdot I)$$

S'ha fixat $T=0.7$. Aquesta estratègia redueix la variància del mostreig, concentrant la generació en les regions d'alta densitat de probabilitat (prop de la mitjana). Això resulta en rostros més nítids i canònics ("cares mitjanes"), a costa de sacrificar lleugerament la diversitat (menys variació en fons o accessoris).

Generación Final (Modelo >10k LL)




Figura 4.1: Mostres aleatòries generades pel model Glow amb temperatura $T=0.7$. S'observa que el model és capaç de generar cares globalment coherents (ulls, nas, boca ben col·locats), tot i que presenten certs artefactes de textura granular característics de l'arquitectura.

4.2. Estratègia de Generació Robusta (Filtratge de NaNs)

Donada la profunditat del model (24 blocs de flux totals) i la precisió de punt flotant, la generació massiva d'imatges és propensa a inestabilitats numèriques, resultant ocasionalment en valors NaN o Inf.

Per garantir la integritat del dataset sintètic, s'ha implementat un algorisme de generació robusta amb filtratge granular:

1. Es generen lots (batches) de candidats latents.
2. Es projecten a l'espai d'imatge.
3. Es verifica la integritat numèrica imatge a imatge (no per lot complet).
4. Es descarten les mostres corruptes i s'acumulen les vàlides fins a assolir l'objectiu de 2.000 imatges per classe (4.000 en total).

Aquesta tècnica ha permès construir un dataset lliure d'errors sense interrompre el flux d'execució.

4.3. Observació sobre el Condicionament de Classes


Tot i que el model genera cares visualment coherents, una inspecció qualitativa preliminar del dataset sintètic revela una limitació important: la manca de distinció visual clara entre les classes generada.

Les imatges generades condicionades a l'etiqueta $y=0$ (No somriu) i $y=1$ (Somriu) presenten característiques facials molt similars. Això suggereix que, durant l'entrenament, el model ha prioritzat l'aprenentatge de les estructures visuals globals (cares) per sobre de la correlació semàntica amb l'etiqueta (Conditional Neglect). Aquest fenomen tindrà implicacions directes en els resultats de classificació que es discuteixen a la secció 6.

4.4. Anàlisi de Novetat: Comparativa amb Veïns Més Propers

Seguint els requisits de l'enunciat, és necessari verificar que el model generatiu no s'ha limitat a memoritzar les dades d'entrenament, overfitting, sinó que és capaç de generar identitats noves.

Per validar-ho, s'ha realitzat una anàlisi de Veïns Més Propers. Per a un conjunt de mostres generades aleatòriament pel Glow, s'ha buscat quina és la imatge del dataset d'entrenament real que té la mínima distància Euclidiana L2 a nivell de píxel.



Com s'observa a la Figura 4.2, encara que el veí més proper comparteix trets estructurals globals amb la imatge generada (com la tonalitat de la pell, el color del fons o el volum del cabell), existeixen diferències notables en els detalls facials.

Les imatges generades presenten variacions en l'expressió (somriure/seriós), la posició dels ulls o la forma exacta de la boca que no tenen una correspondència exacta en el dataset original. Aquest fet confirma que el model Glow no està memoritzant les dades, sinó que ha après correctament la distribució subjacent i és capaç de sintetitzar mostres genuïnament noves.

5. Classificador ResNet18

Per avaluar objectivament la qualitat de les mostres generades pel Glow, no n'hi ha prou amb la inspecció visual. Cal mesurar la seva "utilitat" (utility) mitjançant un model discriminatiu extern. Per a aquest propòsit, s'ha seleccionat una ResNet-18, una arquitectura de referència en visió per computador basada en connexions residuals.

5.1. Arquitectura (Adaptació a Baixa Resolució)

L'arquitectura ResNet-18 estàndard (dissenyada per a ImageNet, 224×224) no és adequada per al nostre dataset de 32×32 a causa de la seva agressiva reducció de dimensionalitat inicial.

En la versió original:

1. La primera convolució (7×7 , stride 2) redueix la imatge a 16×16 .
2. El Max Pooling posterior (3×3 , stride 2) la redueix a 8×8 . Això provocaria que la xarxa perdés el 94% de la informació espacial abans d'entrar al primer bloc residual, fent impossible la detecció de trets facials fins.

Modificació Implementada: Per solucionar-ho, hem modificat la capçalera de la xarxa ("CIFAR Adaptation"):

- Conv1 Substituïda: Es canvia el kernel de 7×7 per un de 3×3 amb stride 1 i padding 1.
- Pooling Eliminat: Es suprimeix la capa de Max Pooling inicial.
- Capa Final: S'adapta la capa lineal (Fully Connected) per tenir 2 sortides (Somriure / No somriure).

Aquesta modificació permet que els tensors d'activació entrin als blocs residuals mantenint la resolució completa de 32×32 , preservant la informació estructural necessària per a la classificació.

5.2. Escenaris d'entrenament

Per quantificar la qualitat del generador, s'han dissenyat tres experiments seqüencials. En tots els casos, el conjunt de validació és el mateix (dades reals) per garantir la comparabilitat dels resultats.

5.2.1 Baseline (Només dades reals)

- Descripció: S'entrena la ResNet exclusivament amb el conjunt d'entrenament original (962 imatges).
- Objectiu: Establir el límit superior de rendiment (Upper Bound) que és capaç d'assolir el classificador amb dades "perfectes". Serveix com a punt de referència (Gold Standard).

5.2.2 TSTR: Train on Synthetic, Test on Real (Només dades sintètiques)

- Descripció: S'entrena la ResNet exclusivament amb 4.000 imatges generades pel model Glow, sense veure cap imatge real durant l'entrenament. S'avalua sobre dades reals.
- Objectiu: Mesurar el "realisme estructural i semàntic". Si el Glow ha après correctament la distribució condicional $P(x|y)$, el classificador hauria de ser capaç de generalitzar a dades reals. Una caiguda dràstica en la precisió indicaria que les imatges sintètiques no contenen la informació discriminant necessària.

5.2.3 Data Augmentation (Dades Mixtes)

- **Descripció:** S'entrena amb la unió del dataset real complet i un subconjunt de dades sintètiques (10 % addicional).
- **Objectiu:** Avaluar si el model generatiu aporta diversitat útil que actuï com a regularitzador, millorant el rendiment del Baseline.

Els tres models s'han entrenat durant 15 èpoques utilitzant l'optimitzador Adam ($\text{lr}=1\text{e}-3$) i la funció de pèrdua Cross Entropy Loss, amb un scheduler per reduir la taxa d'aprenentatge en cas d'estancament.

6. Resultats experimentals

A continuació es presenten els resultats quantitatius obtinguts en els tres escenaris d'entrenament definits. L'avaluació s'ha realitzat monitoritzant la Accuracy (Precisió) i el Loss (Pèrdua) sobre el mateix conjunt de validació real.

6.1. Model entrenat amb dades reals (Baseline)

Aquest experiment estableix el rendiment de referència de l'arquitectura ResNet-18 modificada.

- **Resultats:** El model ha convergit ràpidament, assolint una precisió final del 98.76% al conjunt de validació.
- **Anàlisi:** Aquest resultat confirma que:
 1. El dataset Smiling or Not, tot i ser petit, conté informació visual suficient per distingir les classes amb alta fiabilitat.
 2. L'adaptació arquitectònica (eliminació del pooling inicial) ha estat un èxit, permetent a la xarxa processar eficaçment imatges de 32×32 .

6.2. Model entrenat amb dades sintètiques (TSTR)

En aquest escenari, s'ha entrenat el classificador exclusivament amb 4.000 imatges generades pel Glow i s'ha avaluat sobre dades reals. Els resultats mostren una discrepància extrema entre Entrenament i Validació:

Mètrica	Valor Final	Observació
Train Accuracy	~100%	El model classifica perfectament les dades sintètiques.
Val Accuracy (Real)	~50%	El model es comporta de manera aleatòria amb dades reals.

Les conclusions que podem extreure d'aquest experiment són les següents:

1. Falta de Semàntica: Visualment, les imatges generades per a la classe 0 i la classe 1 són pràcticament indistingibles en termes d'expressió facial.
2. Memorització d'Artefactes: Com és possible obtenir un 100% en Train si les cares són iguals? La ResNet ha trobat patrons imperceptibles de soroll d'alta freqüència o "marques d'aigua" específiques de cada lot generat pel Glow. Ha après a distingir "soroll de classe 0" vs "soroll de classe 1", en lloc de serios vs somriure.
3. Fallada de Generalització: En passar a dades reals, on aquests patrons de soroll sintètic no existeixen, el classificador falla estrepitosament, demostrant que les dades sintètiques generades no són útils per a la discriminació semàntica.

6.3. Model entrenat amb dades mixtes (Data Augmentation)

Finalment, s'ha entrenat el model amb el dataset real original augmentat amb 500 imatges sintètiques.

- Resultats: S'ha obtingut una precisió de validació del 97.93%.
- Comparativa: El rendiment ha disminuït lleugerament respecte al Baseline, experiment 6.1. Això és coherent amb l'anàlisi de l'apartat 6.2: com que les dades sintètiques no aporten informació semàntica clara sobre el somriure, actuen efectivament com a soroll o regularització neutra, sense aportar un benefici significatiu de Data Augmentation.

6.4. Resum de l'avaluació

La taula següent sintetitza l'experimentació:

Experiment	Entrenament	Validació (Real)	Interpretació
Baseline	Real	98.76%	Referència òptima.
Sintètic (TSTR)	Glow (Sintètic)	~50.0%	Fallada en el condicionament de classes del generador.
Mixt	Real + Sintètic	97.93%	Impacte limitat pel soroll semàntic de les mostres.

8. Conclusions

En aquest laboratori s'ha explorat l'ús dels Fluxos Normalitzadors (Normalizing Flows), i concretament de l'arquitectura Glow, com a eina per al modelatge generatiu i l'augment de dades en problemes de classificació d'imatges.

8.1. Capacitat de Modelatge de Densitat i Reconstrucció

El model Glow ha demostrat una capacitat excepcional per aprendre la distribució de píxels del dataset. L'anàlisi de reconstrucció ha validat empíricament la invertibilitat matemàtica del model: les imatges reconstruïdes són visualment indistingibles de les originals, i l'error residual és pràcticament nul (atribuïble només a la precisió numèrica).

8.2. Qualitat de la Generació vs. Condicionament Semàntic

Tot i que el model ha assolit un Log-Likelihood elevat, hem observat una cosa important:

- A nivell global ($P(x)$): El model genera cares humanes coherents, amb estructura facial correcta i sense el "mode collapse" típic de les GANs.
- A nivell condicional ($P(x|y)$): S'ha detectat un fenomen de Conditional Neglect. Tot i proporcionar les etiquetes (somriure/no somriure) durant l'entrenament, el model ha tendit a ignorar-les, generant rostros genèrics molt similars per a ambdues classes. Això suggereix que, per a datasets petits i sorollosos, el model troba més eficient optimitzar la versemblança dels píxels que la correlació amb l'etiqueta.

8.3. Utilitat per a Tasques Discriminatives (TSTR)

L'experiment Train on Synthetic, Test on Real ha actuat com a prova del cotó fluix per a la qualitat semàntica. El fet que el classificador obtingués un 100% de precisió en dades sintètiques però caigués al ~50% (atzar) en dades reals indica que el generador introdueix artefactes d'alta freqüència (marques d'aigua imperceptibles) específics de cada classe, que la xarxa discriminativa memoritza fàcilment. Això demostra que un bon Log-Likelihood no garanteix necessàriament unes mostres útils per a l'entrenament supervisat (Data Augmentation).

8.4. Limitacions Arquitectòniques i Aprenentatge Futur

Hem comprovat que l'arquitectura ResNet estàndard no és viable per a imatges de 32×32 sense modificacions (eliminació del pooling inicial). A més, els resultats suggereixen que per millorar el condicionament del Glow, seria necessari aplicar tècniques més avançades com el Classifier-Free Guidance.

En resum, hem validat el Glow com un excel·lent codificador probabilístic i compressor d'informació.