

ENTREGABLE 2: Time to Explore: DQN with RND and ICM

**Marc Delgado
ARA
Mario Martin
2025-2026**

ÍNDEX

1. Introducció
2. Objectius de la pràctica
3. Entorn de treball: MountainCar Sparse
4. Mètodes d'Exploració implementats
 - 4.1. Random Network Distillation (RND)
 - 4.2. Intrinsic Curiosity Module (ICM)
5. Bonus: Hindsight Experience Replay (HER)
6. Resultats Experimentals i Gràfiques
7. Conclusions
8. Referències
9. Annex

1. Introducció

El paradigma de l'Aprenentatge per Reforç (RL) es basa en la premissa que un agent aprèn a través d'un senyal de recompensa que indica l'èxit o el fracàs de les seves accions. Tanmateix, en molts escenaris del món real, aquest senyal és extremadament escàs (*sparse*). En el cas del **MountainCar**, en la seva versió personalitzada per a aquesta pràctica, l'agent només rep un senyal positiu en arribar a la meta; qualsevol altra acció durant l'exploració rep una recompensa de zero.

Aquest escenari presenta el que es coneix com el "problema de l'agulla en un paller". Un agent que utilitzi una exploració clàssica com **epsilon-greedy** depèn totalment de l'atzar per moure's. En entorns complexos, la probabilitat d'executar la seqüència exacta d'accions necessària per "ensopegar" amb la meta abans que s'esgoti el límit de temps (200 passos) és pràcticament nul·la. Com a resultat, l'agent no rep cap feedback positiu, el gradient d'aprenentatge és zero i el procés d'entrenament s'estanca en un bucle d'exploració inútil.

Per superar aquesta limitació, sorgeixen els mètodes d'**Exploració Intrínseca**. La idea fonamental és dotar l'agent d'una "curiositat" artificial: una recompensa generada internament que incentiva la visita a estats nous o poc coneguts.

En conjunt, aquests mètodes permeten transformar un entorn buit de feedback en un paisatge ric en senyals d'aprenentatge, facilitant la resolució de tasques que, d'una altra manera, serien inaccessibles per a un algorisme de RL estàndard.

2. Objectius

L'objectiu principal d'aquesta pràctica és el disseny i la implementació de mecanismes de motivació intrínseca per resoldre problemes de reforç on el senyal de recompensa és espars, utilitzant l'entorn MountainCar com a banc de proves. Es pretén integrar algorismes d'última generació com **RND** (Random Network Distillation) i **ICM** (Intrinsic Curiosity Module) dins d'una arquitectura DQN, aprenent a gestionar xarxes neuronals paral·leles que generen premis artificials basats en la novetat o la predictibilitat dels estats visitats.

A més de l'exploració intrínseca, la pràctica té com a fita avaluar l'eficàcia del mètode **Hindsight Experience Replay (HER)**, vist en la pràctica anterior, adaptat a espais d'estats continus, comparant la seva capacitat d'aprenentatge a posteriori amb els mètodes basats en la curiositat. Mitjançant l'anàlisi de gràfiques de rendiment i longitud d'episodis, s'espera consolidar el coneixement sobre el *trade-off* entre exploració i explotació, i entendre com la definició de metes virtuals i distàncies euclidianes pot transformar trajectòries fallides en experiències d'aprenentatge valuoses per a l'agent.

3. Entorn de treball: MountainCar Sparse

L'escenari principal d'aquesta pràctica és una versió personalitzada de l'entorn clàssic **MountainCar-v0** de Gymnasium. En la versió original, el cotxe rep una recompensa de -1 per cada pas fins a arribar a la meta, un senyal que, tot i semblar senzill, facilita l'aprenentatge en indicar implícitament que cal minimitzar el temps. No obstant això, per a aquest experiment s'ha aplicat un *wrapper* que transforma la funció de recompensa en una de tipus completament espars: l'agent rep 0 punts en cada *step* i només obté una bonificació de +200 en el moment exacte en què arriba a la bandera situada al cim. Aquesta modificació elimina qualsevol guia intermèdia, obligant l'algorisme a dependre exclusivament d'una exploració efectiva per descobrir l'objectiu per primera vegada.

Per establir una línia de base comparativa, el projecte inclou una prova inicial amb el **MountainCar original** (recompensa densa), on s'observa que un agent DQN estàndard és capaç de convergir ràpidament cap a la solució. Aquest contrast és fonamental per demostrar com un canvi aparentment menor en la definició del reforç pot invalidar mètodes clàssics com epsilon-greedy, que en la versió *sparse* es mostra incapaç de resoldre la tasca en el límit de 200 passos. Així, l'entorn MountainCar Sparse serveix com el marc ideal per validar la necessitat de les recompenses intrínseques de RND i ICM, així com l'eficiència de la memòria virtual proporcionada per HER.




Figura 1: Mountain Car

4. Mètodes d'Exploració implementats

Per resoldre el problema de la recompensa esparsa, s'han integrat dos mòduls que generen un senyal de recompensa intrínseca, la qual se suma a la recompensa extrínseca de l'entorn. D'aquesta manera, l'agent rep un gradient d'aprenentatge constant fins i tot quan no arriba a la meta.

4.1. Random Network Distillation (RND)

El mètode RND es basa en la premissa que l'error de predicció d'una xarxa neuronal tendeix a ser més alt en estats que ha visitat poques vegades. L'arquitectura implementada consta de dues xarxes neuronals:

- **Xarxa Target:** Una xarxa inicialitzada aleatòriament que roman fixa durant tot l'entrenament. Actua com una funció que assigna a cada estat un valor determinista però aleatori.
- **Xarxa Predictor:** Una xarxa amb la mateixa arquitectura que intenta aprendre a predir la sortida de la xarxa *target* per a cada estat visitat.

La recompensa intrínseca es defineix com l'error quadràtic mitjà (MSE) entre la sortida del predictor i el *target*. A mesura que l'agent visita repetidament un estat, el predictor aprèn a imitar la xarxa *target*, l'error disminueix i, per tant, la recompensa intrínseca s'esvaeix, incentivant l'agent a buscar zones noves de l'espai d'estats.

5.2. Intrinsic Curiosity Module (ICM)

A diferència de RND, l'ICM avalua la novetat basant-se en la capacitat de l'agent per predir les conseqüències de les seves pròpies accions en un espai de característiques après. Aquest mòdul està format per tres components principals:

1. **Xarxa de Característiques (Feature Network):** Codifica les observacions en un espai latent de menor dimensió, filtrant el soroll de l'entorn que l'agent no pot controlar.
2. **Model d'Inversa (Inverse Dynamics):** Rep les característiques de l'estat actual i del següent per predir quina acció s'ha realitzat. Això assegura que l'espai de característiques només contingui informació rellevant per a les accions de l'agent.
3. **Model de Dinàmica (Forward Dynamics):** Intenta predir el vector de característiques de l'estat següent a partir de l'estat actual i l'acció realitzada.

En aquest cas, la recompensa intrínseca és l'error de predicció del model de dinàmica (MAE entre la predicció i el següent estat real en l'espai de característiques). L'agent se sent "curiós" per aquelles transicions on el seu model de món falla, cosa que el porta a explorar regions on la dinàmica encara no és familiar.

5. Bonus: Hindsight Experience Replay (HER)

En aquest apartat s'ha integrat la tècnica de **Hindsight Experience Replay (HER)** per tal de complementar la capacitat d'aprenentatge de l'agent en l'escenari de recompensa esparsa del MountainCar. Com ja es va analitzar en la sessió anterior amb el problema de la cadena de bits, la idea central de HER és aprendre dels errors mitjançant el reetiquetatge de trajectòries fallides com si qualsevol estat assolit hagués estat l'objectiu real de l'agent. No obstant això, la implementació per a aquest entorn requereix una adaptació crítica a causa de la naturalesa del seu espai d'estats.

A diferència del problema dels bits, on els estats són discrets i binaris, el MountainCar opera en un **espai d'estats continu** definit per la posició i la velocitat del cotxe. Aquest canvi de domini introdueix dos desafiaments fonamentals que s'han hagut de resoldre:

- **Criteri de proximitat (Goal Achievement):** En un entorn continu, la probabilitat d'arribar exactament a una coordenada específica és pràcticament nul·la. Per tant, s'ha implementat una funció de distància (com ara la distància euclidiana) per determinar si un estat "virtual" s'ha assolit. Es considera que l'objectiu s'ha aconseguit si la distància entre l'estat actual i l'objectiu és inferior a un llindar epsilon definit.
- **Reetiquetatge i recompenses:** Per mantenir una comparació justa amb RND i ICM, s'ha adaptat l'estructura de recompenses de HER: s'assigna una recompensa de 0 si no es troba la solució (fins i tot en les metes virtuals) i de 200 (o 1) quan l'agent arriba a l'estat objectiu reetiquetat.

6. Resultats Experimentals i Gràfiques

6.1. DQN en Mountain Car Original

En la configuració estàndard de l'entorn, on l'agent rep una penalització de -1 per cada unitat de temps, el model DQN demostra una capacitat d'aprenentatge robusta. Els resultats mostren que l'agent aconsegueix desxifrar la combinació de moviments necessaris per vèncer la gravetat i arribar a la bandera aproximadament als 10.000 passos. Un cop trobada la solució, la corba d'aprenentatge s'estabilitza ràpidament, reduint la durada dels episodis des del límit de 200 fins a una mitjana d'entre 140 i 160 passos, la qual cosa indica una convergència eficient cap a una política gairebé òptima.

L'èxit en aquest apartat es deu principalment a la densitat de la recompensa. Com que cada acció té un cost immediat, el gradient de Q-values permet a la xarxa neuronal identificar quines seqüències d'accions l'aproximen més ràpidament a la meta. Tot i la variabilitat inherent al mostreig del *Replay Buffer*, l'agent no perd la política apresada i manté un rendiment constant fins al final de l'entrenament, confirmant que el punt de partida de l'arquitectura DQN és correcte.




Figura 2: DQN en Mountain Car Original

6.2. DQN en Mountain Car Sparse

Quan modifiquem l'entorn per treballar amb recompenses esparses (0 durant l'episodi i +200 només a la meta), el comportament del DQN canvia radicalment. Les gràfiques obtingudes mostren una línia completament plana fixada en els 200 passos durant tota l'execució. Això confirma que l'exploració aleatòria basada en epsilon-greedy és totalment incapaç de trobar l'objectiu en un espai d'estats continu; l'agent mai rep cap senyal de reforç positiu i, per tant, la seva xarxa neuronal no té dades per actualitzar els pesos de forma significativa.

Aquest resultat posa de manifest la limitació fonamental dels mètodes de RL clàssics davant de problemes on la retroalimentació és poc freqüent. Sense un gradient de recompensa que guiï el cotxe cap amunt de la muntanya, l'agent queda atrapat en un bucle d'accions sense sentit. Aquesta mancança justifica la necessitat d'introduir mecanismes d'exploració avançats com la curiositat intrínseca o el re-etiquetatge d'experiències per forçar l'aprenentatge en absència de fites externes.




Figura 3: DQN en Mountain Car Sparse

6.3. Exploration by Random Network Distillation (RND)

La implementació de RND introdueix una recompensa intrínseca basada en l'error de predicció d'una xarxa sobre una altra de fixa. En els nostres experiments, hem observat que l'agent comença a trobar la meta al voltant dels 18.000 passos de temps. La convergència és més erràtica que en el cas original, presentant moltes oscil·lacions en la durada dels episodis. Això s'explica perquè, un cop l'agent aprèn a predir l'estat d'una zona concreta (la "novetat" desapareix), la recompensa intrínseca cau i l'agent pot deixar d'explorar aquesta regió fins que troba un nou estímul.

Tot i aquesta inestabilitat, el mètode és capaç de reduir la longitud dels episodis fins als 130-150 passos en els seus millors moments. L'eliminació de les funcions d'activació ReLU al final de la xarxa predictora ha estat clau per evitar que el mòdul aprengué massa ràpid i deixés de ser informatiu. En conclusió, RND aconsegueix trencar el bloqueig de la recompensa esparsa, tot i que requereix un ajust molt precís dels hiperparàmetres per mantenir una exploració productiva durant tot el procés.





Figura 4: RND en Mountain Car Sparse

6.4. Intrinsic Curiosity Module (ICM)

L'agent comença a mostrar signes de millora molt d'hora, prop dels 12.000 passos, i manté una tendència decreixent més suau que RND. La capacitat de l'ICM per centrar-se només en els canvis de l'estat que són conseqüència directa de les accions de l'agent (mitjançant el model d'inversa) permet filtrar el soroll i centrar l'esforç d'exploració en moviments que realment ajuden a pujar la muntanya.

Pel que fa a la convergència, l'ICM aconsegueix establir-se en solucions d'uns 155 passos de mitjana. L'ombra de desviació típica en les gràfiques indica que les tres execucions independents han seguit camins molt similars, el que suggereix una gran robustesa davant la inicialització aleatòria.



6.5. Anàlisi de Resultats amb HER

En aquest apartat s'analitza els resultats aconseguits amb l'algorisme HER, vist en l'anterior pràctica de laboratori, i també l'impacte del paràmetre **Goal Threshold** (límit de distància a la meta). S'han realitzat tres experiments amb valors de 0.05, 0.10 i 0.15 per observar la relació entre la permissivitat de la meta i la velocitat de convergència.

Taula Comparativa de Resultats

La següent taula resumeix el rendiment de l'agent en les tres configuracions durant els primers 2.000 episodis, però es poden veure els resultats totals en el annex:

Mètrica	Experiment 1 (0.05)	Experiment 2 (0.10)	Experiment 3 (0.15)
Primer èxit detectat	No detectat (>1000 ep)	Episodi 400	Episodi 700

Convergència (Èxit >80%)	Mai	Episodi 600	Episodi 800
Taxa d'èxit final (Ep 2000)	0.0%	87.0%	97.0%
Estabilitat	Nul·la	Alta (mitjana ~92%)	Molt Alta (mitjana ~94%)

1. L'Experiment 0.05 (Fracàs per rigidesa):

Amb un llinar tan estricte, l'agent no ha estat capaç de registrar cap èxit durant els primers 1.000 episodis. Això demostra que, en entorns de recompensa esparsa com el Mountain Car, si el marge d'error és massa petit, la probabilitat de "descobrir" la meta per atzar (necessària per alimentar el buffer de HER) és pràcticament nul·la. L'agent es queda sense feedback positiu per començar a generalitzar.

2. L'Experiment 0.10 (L'equilibri òptim):

Aquest ha resultat ser el valor més eficient en termes de **velocitat d'aprenentatge**. L'agent comença a entendre la tasca a l'episodi 400 i arriba a una taxa d'èxit propera al 90% molt ràpidament (episodi 600). És el llinar que millor equilibra la precisió requerida amb la facilitat per trobar la recompensa inicial.

3. L'Experiment 0.15 (Màxima estabilitat):

Tot i que triga una mica més a arrencar que el de 0.10 (primers èxits a l'episodi 700), un cop l'agent entén el camí, la seva consistència és la més alta, arribant a un **97% d'èxit final**. La major permissivitat facilita que les metes virtuals de HER generin senyals d'aprenentatge constants.

Tot i que el valor de 0.15 acaba amb un percentatge lleugerament superior, el llinar de **0.10** permet que l'agent aprengui de forma molt més prematura. En robòtica o simulacions complexes, minimitzar el nombre d'episodis necessaris per aprendre és crucial. A més, un llinar de 0.10 garanteix que el cotxe arribi realment al cim amb prou precisió, mentre que valors més alts podrien donar per bona una posició que encara no ha superat completament el pendent.

7. Conclusions i comparativa final

La realització d'aquest projecte ha permès constatar que l'èxit d'un agent d'Aprenentatge per Reforç en entorns de recompensa esparsa no depèn de la potència de càlcul, sinó de l'estratègia de gestió del feedback. L'experiment inicial amb DQN Sparse va demostrar que l'exploració aleatòria clàssica és totalment inoperant quan no hi ha un gradient de recompensa que guïi l'agent. En aquest sentit, la implementació de mètodes de motivació intrínseca com RND i ICM ha resultat clau per trencar aquest bloqueig, dotant l'agent d'una "curiositat" artificial que transforma la novetat dels estats en senyals

d'aprenentatge. Mentre que RND destaca per la seva capacitat de descobriment inicial, l'ICM ha demostrat una robustesa superior en centrar-se exclusivament en les conseqüències de les accions de l'agent, filtrant el soroll de l'entorn i estabilitzant la convergència.

D'altra banda, l'anàlisi de l'algorisme Hindsight Experience Replay (HER) ha revelat una perspectiva complementària i extremadament potent: la capacitat de transformar el fracàs en coneixement mitjançant el reetiquetatge de metes. S'ha comprovat que, en espais d'estats continus com el del MountainCar, la definició del llindar de distància (Goal Threshold) és el paràmetre més determinant, on un valor de 0.10 ha demostrat ser l'equilibri òptim entre la precisió de la política i la velocitat de descobriment de la recompensa. Amb taxes d'èxit final de fins al 97%, HER s'ha consolidat com el mètode més eficient per aprofitar cada trajectòria realitzada.

7. Referències

[1] Y. Burda, H. Edwards, A. Storkey, and O. Klimov, "Exploration by random network distillation," in International Conference on Learning Representations, 2019.

[2] D. Pathak, P. Agrawal, A. A. Efros, and T. Darrell, "Curiosity-driven exploration by self-supervised prediction," in Proceedings of the 34th International Conference on Machine Learning- Volume 70, ser. ICML'17. JMLR.org, 2017, p. 2778–2787.

8. Annex

1. HER amb goal threshold de 0.05

```
>>> Fent servir dispositiu: cuda

--- EXPERIMENT: DIST_LIMIT = 0.05 ---
Ep 100 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.82
Ep 200 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.67
Ep 300 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.55
Ep 400 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.45
Ep 500 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.37
Ep 600 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.30
Ep 700 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.25
Ep 800 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.20
Ep 900 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.17
Ep 1000 | Reward: 0.0 | Èxit: 0.0% | Eps: 0.14
```

2. HER amb goal threshold de 0.1

```
>>> Fent servir dispositiu: cuda
```

```
--- EXPERIMENT: DIST_LIMIT = 0.1 ---
```

Ep 100		Reward: 0.0		Èxit: 0.0%		Eps: 0.82
Ep 200		Reward: 0.0		Èxit: 0.0%		Eps: 0.67
Ep 300		Reward: 0.0		Èxit: 0.0%		Eps: 0.55
Ep 400		Reward: 0.0		Èxit: 1.0%		Eps: 0.45
Ep 500		Reward: 200.0		Èxit: 60.0%		Eps: 0.37
Ep 600		Reward: 200.0		Èxit: 89.0%		Eps: 0.30
Ep 700		Reward: 200.0		Èxit: 90.0%		Eps: 0.25
Ep 800		Reward: 200.0		Èxit: 92.0%		Eps: 0.20
Ep 900		Reward: 200.0		Èxit: 94.0%		Eps: 0.17
Ep 1000		Reward: 200.0		Èxit: 89.0%		Eps: 0.14
Ep 1100		Reward: 200.0		Èxit: 92.0%		Eps: 0.11
Ep 1200		Reward: 200.0		Èxit: 94.0%		Eps: 0.09
Ep 1300		Reward: 200.0		Èxit: 97.0%		Eps: 0.07
Ep 1400		Reward: 200.0		Èxit: 90.0%		Eps: 0.06
Ep 1500		Reward: 200.0		Èxit: 88.0%		Eps: 0.05
Ep 1600		Reward: 200.0		Èxit: 95.0%		Eps: 0.05
Ep 1700		Reward: 200.0		Èxit: 95.0%		Eps: 0.05
Ep 1800		Reward: 200.0		Èxit: 96.0%		Eps: 0.05
Ep 1900		Reward: 200.0		Èxit: 86.0%		Eps: 0.05
Ep 2000		Reward: 200.0		Èxit: 87.0%		Eps: 0.05

3. HER amb goal threshold de 0.15

```
>>> Fent servir dispositiu: cuda
```

```
--- EXPERIMENT: DIST_LIMIT = 0.15 ---
```

Ep 100		Reward: 0.0		Èxit: 0.0%		Eps: 0.82
Ep 200		Reward: 0.0		Èxit: 0.0%		Eps: 0.67
Ep 300		Reward: 0.0		Èxit: 0.0%		Eps: 0.55
Ep 400		Reward: 0.0		Èxit: 0.0%		Eps: 0.45
Ep 500		Reward: 0.0		Èxit: 0.0%		Eps: 0.37
Ep 600		Reward: 0.0		Èxit: 0.0%		Eps: 0.30
Ep 700		Reward: 200.0		Èxit: 5.0%		Eps: 0.25
Ep 800		Reward: 200.0		Èxit: 82.0%		Eps: 0.20
Ep 900		Reward: 200.0		Èxit: 92.0%		Eps: 0.17
Ep 1000		Reward: 200.0		Èxit: 95.0%		Eps: 0.14
Ep 1100		Reward: 200.0		Èxit: 83.0%		Eps: 0.11
Ep 1200		Reward: 200.0		Èxit: 95.0%		Eps: 0.09
Ep 1300		Reward: 200.0		Èxit: 89.0%		Eps: 0.07
Ep 1400		Reward: 200.0		Èxit: 96.0%		Eps: 0.06
Ep 1500		Reward: 200.0		Èxit: 92.0%		Eps: 0.05
Ep 1600		Reward: 200.0		Èxit: 92.0%		Eps: 0.05
Ep 1700		Reward: 200.0		Èxit: 98.0%		Eps: 0.05
Ep 1800		Reward: 200.0		Èxit: 90.0%		Eps: 0.05
Ep 1900		Reward: 200.0		Èxit: 92.0%		Eps: 0.05
Ep 2000		Reward: 200.0		Èxit: 97.0%		Eps: 0.05