

INFORME APRNS PRÁCTICA 5

**Marc Delgado
APRNS
2025-2026**

ÍNDICE

1. Introducción
2. Conjuntos de datos
 - 2.1 CIFAR-10
 - 2.2 STL-10
 - 2.3 Particiones de datos
 - 2.4 Visualización de ejemplos
3. Extracción de características con VAE
 - 3.1 Modelo VAE utilizado
 - 3.2 Representación latente
 - 3.3 Proceso de extracción de latentes
4. Modelos de clasificación
 - 4.1 Perceptrón Multicapa (MLP)
 - 4.2 Red Convolutacional (CNN)
 - 4.3 Clasificador basado en centroides
5. Experimentos y resultados
 - 5.1. Clasificación intra-set
 - 5.2 Transferencia entre conjuntos de datos (cross-dataset)
6. Análisis del espacio latente
 - 6.1 Visualización del espacio latente
 - 6.2 Reconstrucción de imágenes a partir del espacio latente
7. Matrices de confusión
 - 7.1 Clasificador basado en centroides (L2)
 - 7.2 Red neuronal convolucional (CNN)
 - 7.3. Perceptrón multicapa(MLP)
8. Conclusiones

1. Introducción

En este trabajo queremos analizar la calidad de las representaciones latentes generadas por un VAE preentrenado, concretamente el VAE utilizado en el modelo *Stable Diffusion*, y estudiar su capacidad para transferir conocimiento entre dos conjuntos de datos clásicos de visión por computador: CIFAR-10 y STL-10. Ambos conjuntos contienen clases visualmente similares, aunque presentan diferencias en resolución, distribución y estilo de las imágenes, lo que los convierte en un escenario adecuado para evaluar transferencia entre dominios.

Para llevar a cabo este análisis, se seleccionan cuatro clases comunes a ambos conjuntos de datos (airplane, automobile/car, bird y truck), y se generan representaciones latentes de tamaño reducido ($4 \times 4 \times 4$, equivalentes a 64 dimensiones) mediante el codificador del VAE. A partir de estas representaciones, se entrenan distintos tipos de clasificadores, incluyendo un perceptrón multicapa (MLP) y una red neuronal convolucional (CNN), evaluando su rendimiento tanto en escenarios intra-dataset como en transferencia cruzada entre CIFAR-10 y STL-10. Asimismo, se incluye un clasificador simple basado en centroides de clase, con el objetivo de analizar la estructura del espacio latente sin recurrir a modelos complejos.

El objetivo final del trabajo es evaluar si las representaciones latentes generadas por un VAE preentrenado son suficientemente informativas y robustas como para permitir clasificación precisa y transferencia de conocimiento entre dominios visuales relacionados.

2. Conjuntos de datos

En este trabajo se utilizan dos conjuntos de datos ampliamente conocidos en el ámbito de la visión por computador: **CIFAR-10** y **STL-10**. Ambos contienen imágenes de objetos cotidianos organizadas en clases similares, pero presentan diferencias importantes en resolución, distribución y estilo visual, lo que los convierte en un escenario adecuado para analizar la transferencia de conocimiento entre dominios relacionados.

2.1 CIFAR-10

CIFAR-10 es un conjunto de datos compuesto por 60 000 imágenes en color de tamaño 32×32 píxeles, distribuidas en 10 clases con 6 000 imágenes por clase. El conjunto se divide de forma

estándar en 50 000 imágenes de entrenamiento y 10 000 imágenes de test. Las imágenes representan objetos comunes como aviones, automóviles, animales y vehículos, con una gran variabilidad intra-clase.

Para este trabajo se seleccionan únicamente cuatro clases que tienen correspondencia directa con STL-10: *airplane*, *automobile*, *bird*, *truck*.

Estas clases se eligen por ser visualmente comparables entre ambos conjuntos de datos y permitir un análisis equilibrado de transferencia. Las imágenes de CIFAR-10 ya se encuentran en resolución 32×32 , por lo que no es necesario aplicar ningún reescalado adicional. Antes de ser procesadas por el VAE, las imágenes se normalizan al rango $[-1, 1]$, tal y como requiere el modelo de Stable Diffusion.

2.2 STL-10

STL-10 es un conjunto de datos diseñado específicamente para evaluar algoritmos de aprendizaje no supervisado y transferencia. Contiene imágenes en color de mayor resolución, 96×96 píxeles, organizadas en 10 clases, muchas de las cuales coinciden conceptualmente con las de CIFAR-10. El conjunto incluye 5.000 imágenes de entrenamiento etiquetadas (500 por clase) y 8.000 imágenes de test (800 por clase).

Al igual que en el caso de CIFAR-10, se seleccionan las cuatro clases comunes: *airplane*, *car*, *bird* y *truck*. Para facilitar la comparación directa entre ambos conjuntos y garantizar la compatibilidad con el VAE y los modelos de clasificación posteriores, las imágenes de STL-10 se reescalan a 32×32 píxeles. Tras el reescalado, se aplica la misma normalización al rango $[-1, 1]$, asegurando que ambas bases de datos se procesen bajo condiciones equivalentes.

2.3 Particiones de datos

Con el fin de realizar experimentos controlados y comparables, se construyen particiones de entrenamiento, validación y test de tamaño fijo para ambos conjuntos de datos y para cada una de las cuatro clases seleccionadas. En concreto, se utilizan las siguientes particiones por clase:

- **500 imágenes para entrenamiento**, extraídas de la partición de entrenamiento original.
- **100 imágenes para validación**, extraídas de la partición de test original.
- **100 imágenes para test**, también extraídas de la partición de test original.

De este modo, cada conjunto de datos contiene un total de 2.000 imágenes de entrenamiento, 400 de validación y 400 de test, garantizando un equilibrio perfecto entre clases y permitiendo una comparación justa entre CIFAR-10 y STL-10. Esta estrategia asegura que las diferencias observadas en los resultados se deban principalmente a las propiedades de las representaciones aprendidas y no a desbalances en los datos.

2.4 Visualización de ejemplos

Con el objetivo de comprender mejor las características visuales de ambos conjuntos de datos, se muestran a continuación algunos ejemplos representativos de las imágenes utilizadas en los experimentos. Se presentan imágenes aleatorias de las clases seleccionadas tanto de CIFAR-10 como de STL-10. Esta visualización permite apreciar diferencias claras entre ambos conjuntos de datos, como el nivel de detalle, el estilo visual y la variabilidad intra-clase. En particular, las imágenes de STL-10 presentan una mayor complejidad visual y riqueza de detalles, mientras que las de CIFAR-10 son más simples y de menor resolución. Estas diferencias motivan el uso de representaciones latentes comunes y justifican el interés en analizar la transferencia de conocimiento entre ambos dominios.



3. Extracción de características con VAE

En esta sección se describe el modelo de autocodificador variacional utilizado como extractor de características y la representación latente obtenida a partir de las imágenes de CIFAR-10 y STL-10. El objetivo principal es aprovechar un VAE preentrenado para generar representaciones compactas y semánticamente relevantes que puedan utilizarse posteriormente en tareas de clasificación y transferencia entre conjuntos de datos.

3.1 Modelo VAE utilizado

Para la extracción de características se emplea el Variational Autoencoder (VAE) utilizado en el modelo Stable Diffusion, concretamente el modelo [sd-vae-ft-ema](#) proporcionado a través de la librería *diffusers*. Este VAE ha sido entrenado previamente sobre un conjunto de datos muy amplio de imágenes naturales.

El VAE es un modelo totalmente convolucional, lo que le permite procesar imágenes de distintos tamaños. En este trabajo, tanto las imágenes de CIFAR-10 como las de STL-10 (reescaladas a 32×32) se introducen en el codificador del VAE sin necesidad de modificar su arquitectura. Durante la extracción de características se utiliza exclusivamente el codificador, manteniendo el modelo en modo

evaluación y sin actualizar sus pesos, ya que el VAE se emplea únicamente como extractor fijo de representaciones.

El proceso de codificación consiste en mapear cada imagen de entrada a una distribución gaussiana en el espacio latente, caracterizada por una media y una varianza.

3.2 Representación latente

Al aplicar el codificador del VAE a imágenes de tamaño 32×32 , se obtiene una representación latente de tamaño $4 \times 4 \times 4$, es decir, cuatro mapas espaciales de 4×4 , lo que equivale a un total de 64 dimensiones por imagen. Esta reducción supone una compresión significativa respecto a la imagen original, preservando al mismo tiempo información relevante de alto nivel.

Estas representaciones latentes constituyen la base de todos los experimentos posteriores. Para los clasificadores basados en perceptrones multicapa y centroides, los mapas latentes se aplanan en vectores de 64 dimensiones. En cambio, para los clasificadores convolucionales, se mantiene la estructura espacial $4 \times 4 \times 4$, permitiendo a la red explotar relaciones locales dentro del espacio latente.

El uso de una representación latente común para CIFAR-10 y STL-10 permite analizar hasta qué punto el VAE genera un espacio compartido entre ambos conjuntos de datos. Este aspecto resulta clave para evaluar la capacidad de transferencia de los modelos entrenados y para interpretar los resultados obtenidos en los experimentos de clasificación cruzada.

3.3 Proceso de extracción de latentes

Una vez definidos los conjuntos de datos y cargado el modelo VAE, se procede a la extracción sistemática de las representaciones latentes para todas las imágenes de entrenamiento, validación y test. Este proceso se implementa mediante un procedimiento en batch, utilizando un DataLoader para procesar las imágenes de forma eficiente y evitar problemas de memoria.

Para cada batch de imágenes, estas se transfieren al dispositivo de cómputo y se introducen en el codificador del VAE. El codificador produce, para cada imagen, una distribución gaussiana en el espacio latente. En lugar de muestrear de dicha distribución, se utiliza directamente su media (mode), ya que proporciona una representación determinista y más estable, adecuada para tareas de clasificación supervisada.

Las representaciones latentes obtenidas tienen una dimensión de $4 \times 4 \times 4$ y se almacenan en tensores, preservando su estructura espacial. De forma paralela, las etiquetas originales de cada conjunto de datos se remapean a un espacio de etiquetas común de cuatro clases, garantizando la coherencia entre CIFAR-10 y STL-10.

Finalmente, los latentes y las etiquetas se concatenan para formar los conjuntos definitivos de entrenamiento, validación y test en el espacio latente. Estas representaciones constituyen la entrada de todos los clasificadores evaluados en los experimentos posteriores.

4. Modelos de clasificación

En esta sección se describen los distintos modelos de clasificación empleados para evaluar la calidad y capacidad de transferencia de las representaciones latentes generadas por el VAE. Todos los modelos se entrenan y evalúan exclusivamente sobre el espacio latente, sin actualizar en ningún momento los pesos del VAE, que actúa como extractor fijo de características.

4.1 Perceptrón Multicapa (MLP)

El primer modelo considerado es un perceptrón multicapa profundo con conexiones residuales, diseñado para clasificar las representaciones latentes aplanadas en vectores de 64 dimensiones. La arquitectura comienza con una capa de proyección lineal que transforma el vector latente de entrada en un espacio de mayor dimensionalidad (entre 128 y 384 unidades, según el experimento), seguida de normalización por batches y una función de activación no lineal.

A continuación, se incorporan varios bloques residuales totalmente conectados. Cada bloque consta de dos capas lineales con normalización y activación, junto con una conexión residual que suma la entrada del bloque a su salida. Este diseño permite entrenar redes más profundas sin degradación del gradiente y favorece la estabilidad durante el entrenamiento.

Finalmente, el modelo incluye una cabeza de clasificación formada por una o dos capas densas adicionales que reducen progresivamente la dimensionalidad hasta obtener las cuatro clases finales. Se emplea regularización mediante dropout y, en algunos experimentos, regularización L2 (weight decay) para mitigar el sobreajuste.

Los hiperparámetros explorados para el MLP incluyen la tasa de aprendizaje, el tamaño de la capa oculta, el número de bloques residuales, la tasa de dropout y el factor de regularización L2. La selección del mejor modelo se realiza mediante validación cruzada simple sobre el conjunto de validación.

4.2 Red Neuronal Convolutiva (CNN)

Además del MLP, se evalúa una red neuronal convolutiva diseñada específicamente para operar directamente sobre la estructura espacial de las representaciones latentes, sin aplanarlas. En este caso, los latentes de tamaño $4 \times 4 \times 4$ se interpretan como pequeños mapas de características con cuatro canales.

La arquitectura CNN consta de dos bloques convolucionales principales. El primero emplea convoluciones con kernel de tamaño 3 o 5 para extraer patrones locales, seguido de normalización por lotes y funciones de activación ReLU. El segundo bloque incrementa el número de canales y utiliza una convolución adicional de 1×1 para mezclar la información entre canales de forma eficiente.

Tras los bloques convolucionales, se aplica un pooling global adaptativo que reduce cada mapa de activaciones a un único valor por canal. Finalmente, una pequeña cabeza fully-connected se encarga de la clasificación final. Al igual que en el MLP, se emplea dropout en la fase de clasificación para mejorar la generalización.

Los hiperparámetros explorados para la CNN incluyen el número de filtros base, el tamaño del kernel convolutivo, la tasa de dropout y la tasa de aprendizaje. El modelo se entrena también en régimen full-batch, con selección basada en validación.

4.3 Clasificador basado en centroides

Como modelo de referencia adicional, se implementa un clasificador extremadamente simple basado en centroides de clase en el espacio latente. Para cada clase, se calcula el vector medio de las representaciones latentes del conjunto de entrenamiento, obteniendo así un prototipo o centroide por clase.

Durante la fase de evaluación, cada muestra de test se asigna a la clase cuyo centroide se encuentra a menor distancia según una métrica determinada. Se evalúan tres métricas de distancia: distancia euclídea (L2), distancia Manhattan (L1) y distancia coseno.

5. Experimentos y resultados

En esta sección se presentan los experimentos realizados para evaluar la calidad de las representaciones latentes extraídas mediante el VAE y su utilidad en tareas de clasificación. Se analizan tanto escenarios de clasificación dentro del mismo conjunto de datos como situaciones de transferencia entre CIFAR-10 y STL-10. Los resultados se reportan para los tres modelos considerados: MLP, CNN y clasificador basado en centroides.

Todos los modelos se seleccionan mediante validación y se evalúan posteriormente sobre conjuntos de test independientes.

5.1 Clasificación intra-dataset

En primer lugar, se evalúa el rendimiento de los modelos cuando se entrenan y evalúan sobre el mismo conjunto de datos. Este experimento permite medir hasta qué punto las representaciones latentes son discriminativas dentro de un mismo dominio.

MLP

El MLP obtiene resultados competitivos en ambos conjuntos de datos. En CIFAR-10 alcanza una precisión del **61.75%**, mientras que en STL-10 el rendimiento es notablemente superior, con un **73.00%** de precisión en test. Esta diferencia puede explicarse por el hecho de que STL-10 contiene imágenes de mayor resolución original y con menor ruido visual, lo que facilita que el VAE genere representaciones latentes más separables.

CNN

La CNN muestra un comportamiento similar, aunque con una ligera mejora respecto al MLP en CIFAR-10. En este caso, la CNN alcanza un **67.00%** de precisión en CIFAR-10 y un **70.50%** en STL-10. El mejor rendimiento en CIFAR-10 sugiere que explotar la estructura espacial del espacio latente resulta beneficioso incluso cuando la resolución del mapa latente es reducida (4×4).

Centroides

El clasificador por centroides obtiene resultados más modestos, con precisiones alrededor del **55–58%** en ambos conjuntos de datos, dependiendo de la métrica de distancia utilizada. A pesar de su simplicidad, estos resultados indican que las clases forman agrupaciones razonables en el espacio latente, aunque no tan separadas como para permitir una clasificación perfecta mediante fronteras lineales simples.

Dataset	Distancia	Accuracy
CIFAR-10	L2	55.00%
CIFAR-10	L1	56.25%
CIFAR-10	Coseno	57.75%
STL-10	L2	56.00%
STL-10	L1	56.50%
STL-10	Coseno	55.75%

5.2 Transferencia entre conjuntos de datos (cross-dataset)

El segundo bloque de experimentos evalúa la capacidad de transferencia de los modelos. En este caso, los clasificadores se entrenan en un conjunto de datos y se evalúan directamente sobre el otro, sin ningún ajuste adicional.

MLP

Cuando el MLP se entrena en CIFAR-10 y se evalúa en STL-10, alcanza una precisión del **54.00%**, mientras que en la dirección inversa (entrenado en STL-10 y evaluado en CIFAR-10) obtiene un **56.50%**. Aunque estos valores son inferiores a los obtenidos en clasificación intra-dataset, se sitúan claramente por encima del azar (25%), lo que demuestra que el espacio latente aprendido por el VAE es parcialmente compartido entre ambos dominios.

CNN

La CNN presenta un comportamiento similar, pero ligeramente superior en transferencia CIFAR→STL, alcanzando un **59.50%**, frente al **56.75%** en la dirección STL→CIFAR. Este resultado sugiere que la CNN es capaz de capturar patrones espaciales en el espacio latente que resultan más robustos frente al cambio de dominio.

En general, la transferencia resulta más efectiva cuando el modelo se entrena en STL-10 y se evalúa en CIFAR-10 que en la dirección opuesta, lo que puede deberse a que las representaciones latentes extraídas de STL-10 son más ricas y generalizables.

Centroides

El método basado en centroides obtiene resultados claramente inferiores a los modelos neuronales, aunque mantiene un rendimiento por encima del azar en todos los casos. Las distancias L1 y coseno superan sistemáticamente a L2, lo que indica que la orientación de los vectores latentes es más informativa que su magnitud. Estos resultados confirman que el espacio latente del VAE posee estructura semántica, pero que modelos más expresivos son necesarios para explotarla eficazmente.

Entrenado en	Evaluated en	Distancia	Accuracy
CIFAR-10	STL-10	L2	42.25%
CIFAR-10	STL-10	L1	44.50%
CIFAR-10	STL-10	Coseno	44.50%
STL-10	CIFAR-10	L2	41.25%
STL-10	CIFAR-10	L1	41.75%
STL-10	CIFAR-10	Coseno	42.00%

6. Análisis del espacio latente

En esta sección se analiza la estructura del espacio latente generado por el VAE preentrenado, con el objetivo de comprender mejor el comportamiento observado en los experimentos de clasificación y transferencia entre CIFAR-10 y STL-10. Para ello, se emplean técnicas de reducción de dimensionalidad y visualización, así como un análisis cualitativo de las reconstrucciones generadas por el decodificador del VAE.


6.1 Visualización del espacio latente


Dado que las representaciones latentes obtenidas tienen dimensión 64 ($4 \times 4 \times 4$), se utilizan métodos de reducción de dimensionalidad para proyectarlas a dos dimensiones y facilitar su visualización. En concreto, se emplean **PCA** y **t-SNE**, que ofrecen perspectivas complementarias del espacio latente.

PCA (Principal Component Analysis) permite observar la estructura global del espacio latente preservando la máxima varianza posible. En las proyecciones PCA de CIFAR-10 y STL-10 se aprecia un fuerte solapamiento entre clases, lo que indica que el VAE no genera separaciones lineales claras entre categorías semánticas.

Por otro lado, **t-SNE** pone énfasis en las relaciones locales entre muestras, revelando agrupaciones más compactas a nivel local. En las visualizaciones t-SNE se observan regiones donde ciertas clases tienden a concentrarse parcialmente (por ejemplo, vehículos frente a animales), aunque sigue existiendo un solapamiento significativo. Esto explica por qué los clasificadores supervisados (MLP y CNN) logran mejorar el rendimiento respecto al clasificador por centroides, pero no alcanzan separaciones perfectas entre clases.

Comparando ambos conjuntos de datos, se observa que las representaciones latentes de STL-10 tienden a mostrar una estructura ligeramente más definida que las de CIFAR-10, lo cual concuerda con los mejores resultados obtenidos cuando los modelos se entrenan sobre STL-10 y se evalúan sobre CIFAR-10. Esto sugiere que las imágenes de mayor resolución original de STL-10 aportan información más rica al espacio latente, incluso tras el reescalado






6.2 Reconstrucción de imágenes a partir del espacio latente

Además del análisis geométrico del espacio latente, se realiza un estudio cualitativo mediante la reconstrucción de imágenes utilizando el decodificador del VAE. Para cada conjunto de datos se selecciona una imagen representativa de cada una de las cuatro clases consideradas y se compara la imagen original con su reconstrucción.

Las reconstrucciones muestran que el VAE es capaz de preservar la estructura global y el contenido semántico principal de las imágenes, como la forma general de los objetos y su disposición espacial. Sin embargo, se observa una pérdida de detalle fino y texturas, especialmente notable en objetos pequeños o con contornos complejos. Este comportamiento es esperable dada la fuerte compresión del espacio latente (64 dimensiones) y confirma que el VAE prioriza la representación de características de alto nivel frente a detalles locales.






7. Matrices de confusión

Con el objetivo de analizar en mayor detalle el comportamiento de los distintos modelos, se muestran a continuación las matrices de confusión correspondientes a la clasificación intra-dataset (CIFAR → CIFAR). Estas matrices permiten identificar qué clases son más fácilmente confundidas y ofrecen una interpretación más fina que la accuracy global.

7.1 Clasificador basado en centroides (L2)

La matriz de confusión del clasificador basado en centroides utilizando distancia L2 muestra un rendimiento limitado en comparación con los modelos neuronales. Aunque las clases *avión* y *pájaro* presentan una tasa de aciertos razonable, se observa una confusión significativa entre las clases *coche* y *camión*.


Este comportamiento es esperable, ya que el clasificador por centroides asume que cada clase puede representarse adecuadamente mediante un único punto medio en el espacio latente, lo cual resulta una simplificación excesiva para clases visualmente similares. No obstante, el hecho de que el modelo alcance accuracies superiores al azar confirma que el espacio latente del VAE contiene información semántica relevante.



7.2 Red neuronal convolucional (CNN)

La CNN entrenada sobre representaciones latentes presenta una matriz de confusión claramente más diagonal, indicando un mayor número de predicciones correctas por clase. Las clases *avión* y *pájaro* son clasificadas con alta precisión, mientras que *coche* y *camión* siguen siendo las más conflictivas, aunque con una reducción notable de errores respecto al clasificador de centroides.


Este resultado sugiere que la CNN es capaz de explotar la estructura espacial del espacio latente ($4 \times 4 \times 4$), capturando patrones locales que no son accesibles para modelos puramente vectoriales.



7.3 Perceptrón Multicapa (MLP)

El MLP muestra un comportamiento intermedio entre la CNN y el clasificador por centroides. La matriz de confusión refleja una buena capacidad de discriminación para las clases *avión* y *pájaro*, mientras que persisten errores entre *coche* y *camión*, similares a los observados en la CNN, aunque con una ligera degradación en algunas clases.

A pesar de no aprovechar explícitamente la estructura espacial del espacio latente, el MLP logra resultados competitivos.



8. Conclusiones

En este trabajo se ha analizado la capacidad de transferencia de las representaciones latentes generadas por un VAE preentrenado de Stable Diffusion entre los conjuntos de datos CIFAR-10 y STL-10. Los resultados muestran que el espacio latente aprendido es altamente informativo y permite entrenar clasificadores efectivos incluso en escenarios de transferencia cruzada entre dominios.

Los modelos neuronales (MLP y CNN) superan claramente al clasificador basado en centroides, lo que pone de manifiesto la necesidad de modelos con mayor capacidad para explotar la estructura del espacio latente. En particular, la CNN obtiene los mejores resultados globales, evidenciando que la organización espacial de los latentes es relevante.

Finalmente, el análisis visual mediante PCA y t-SNE confirma que el VAE organiza las imágenes según criterios semánticos coherentes, aunque con solapamientos entre clases visualmente similares. En conjunto, estos resultados validan el uso de VAEs preentrenados como extractores de características robustos y transferibles para tareas de visión por computador.